AI BOOTCAMP SECTION 02 PROJECT

AI 부트캠프 10기 박민경

“목차”

1. 문제 제시

2. 가설 설정

3. 모델 학습

4. 해석 및 결론

1. 문제 제시

📌 문제 제시: 43912명의 결혼 여부, 성별, 인종, 교육 수준 등에 관련해 소득이 $50000 넘는지 예측하기 ▶ **"분류 문제"**

📌 문제 선정 이유: 각자 가지고 있는 다른 배경이 소득에 어떤 영향을 주는지 알아보기 위해

📌 타겟 변수는 income_>50K

📌 age : 나이 workclass : 고용 형태 income_>50K: 소득이 $50K 넘는지
fnlwgt : 사람 대표성을 나타내는 가중치 (final weight의 약자) education : 교육 수준
education_num : 교육 수준 수치 marital_status: 결혼 상태 occupation : 업종
relationship : 가족 관계 race : 인종 sex : 성별 native_country : 국적
capital_gain : 자본이익 capital_loss : 자본손실 hours_per_week : 주당 근무 시간

2. 가설 설정

더 많은 교육을 받은 사람이
소득>$50000일 가능성이 높다.

주당 근무 시간이 많을수록
소득 > $50000일 것이다.

고용 형태가 소득에 영향을 줄
것이다.(일하지 않는 이는
소득>$50000일 가능성이 낮다.)

2. 가설 설정

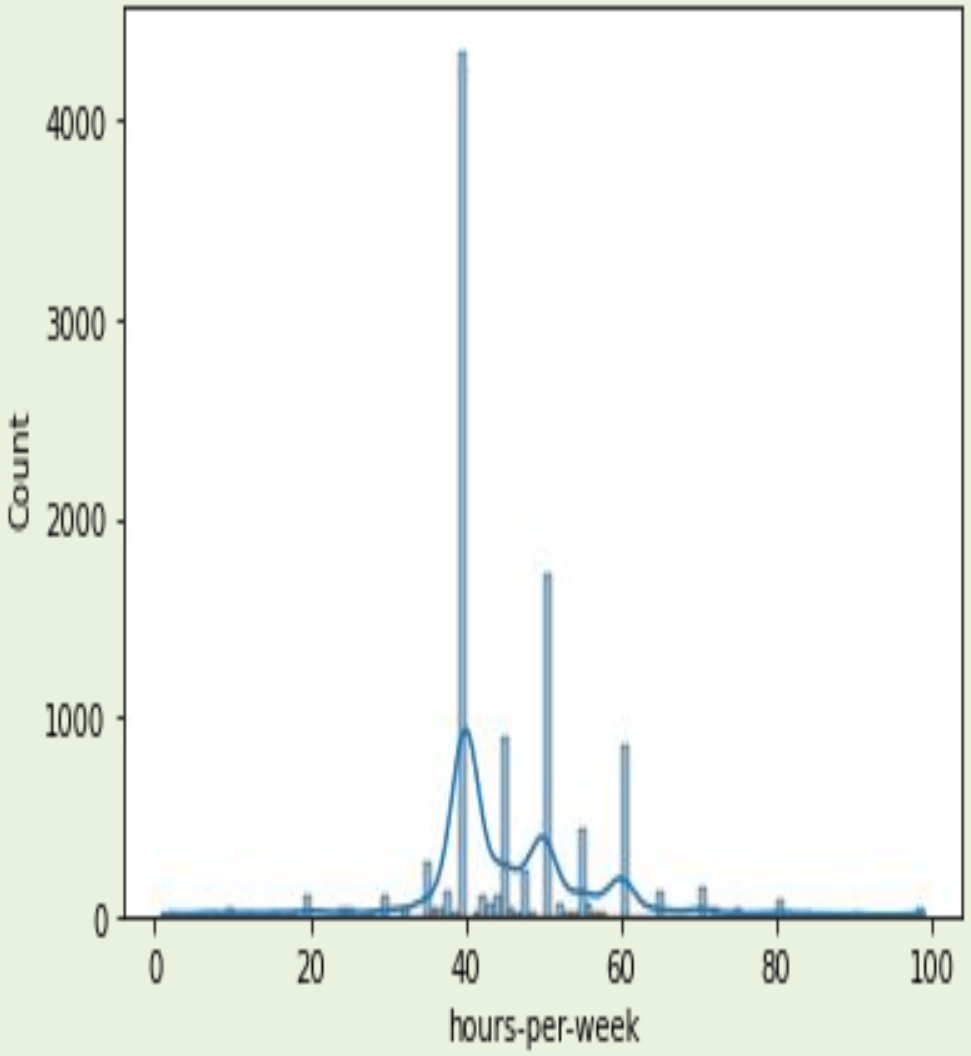

📌 가설 1

- 40~60시간이 가장 많이 분포되어 있다.
- 60시간 이상인 경우가 거의 없다는 점에서 해당 가설을 기각할 수 있다.
- 그러나 주간 근무 시간이 소득>$50000에는 어떤 영향을 주고 있음을 확인할 수 있다.

2. 가설 설정

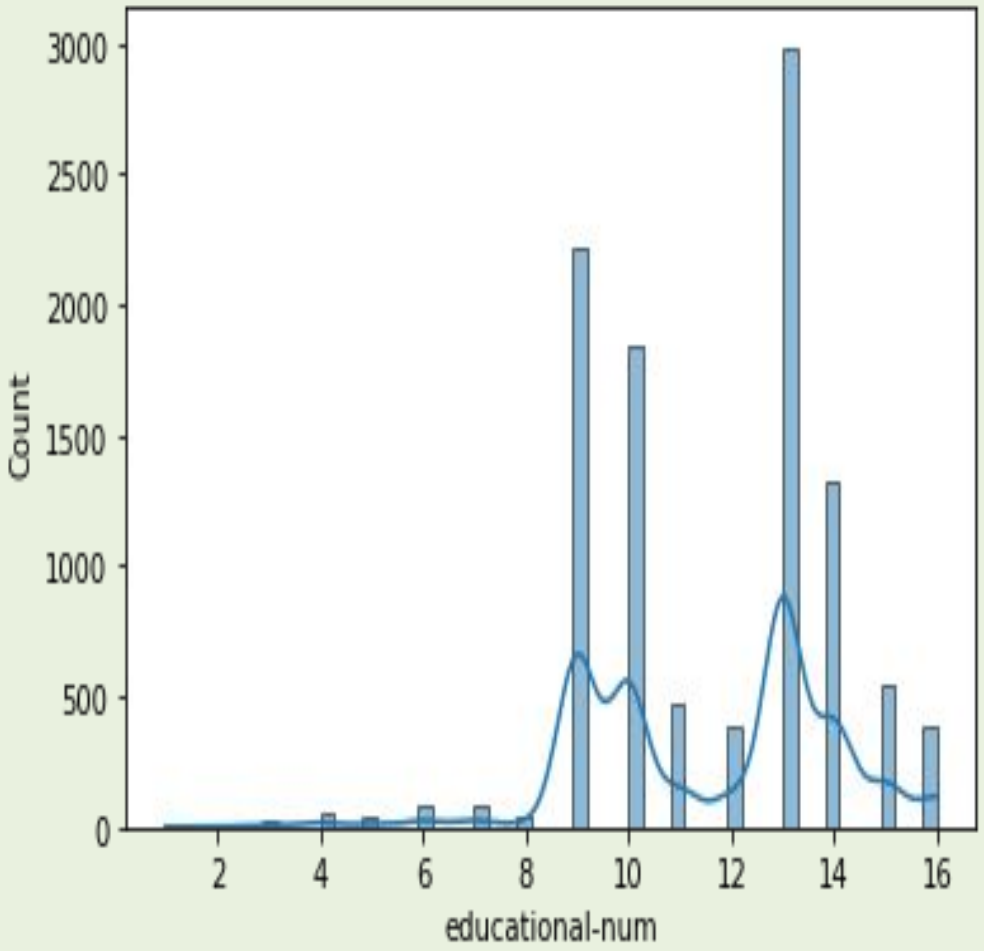

📌 가설 2

- 교육수준 수치가 9~14일 때 가장 많이 분포되어 있다.
- 15 이상인 경우 분포가 적다는 점에서 해당 가설을 기각할 수 있다.
- 그러나 **일정 수준 이상의 교육을 받은 사람이 많이 분포**했으므로 해당 변수가 타겟에 영향을 준다고는 볼 수 있다.

2. 가설 설정

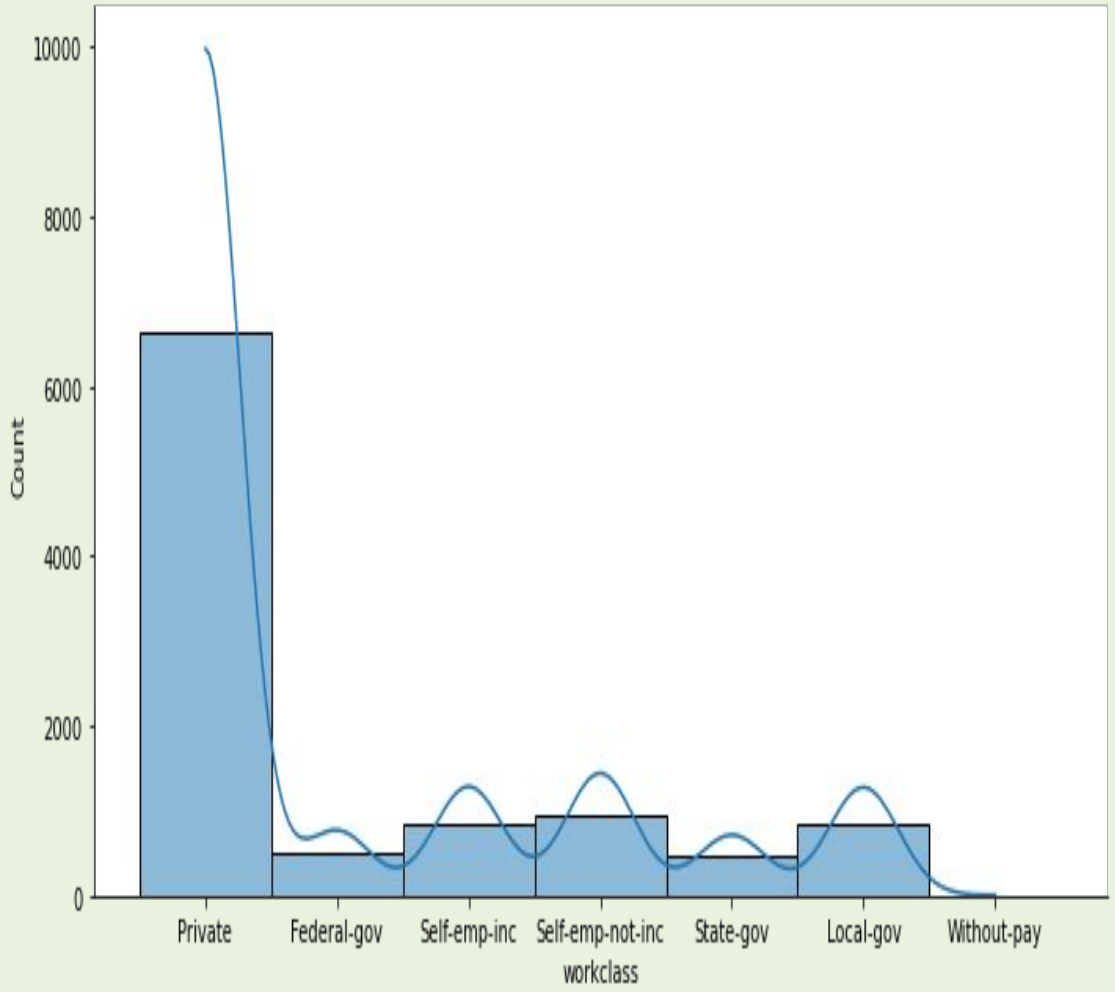

📌 가설 3

- never-work의 분포가 없으며, without-pay인 경우도 거의 존재하지 x
- 고용되지 않거나 임금을 받지 못하는 경우가 소득>$50000의 분포에 거의 존재하지 않다는 점에서 기각할 수 없다고 할 수 있다.

2. 가설 설정

📌 Baseline

- 타겟이 binary 변수이며 분류 문제를 풀어야 하기 때문에 타겟 변수의 최빈값을 기준모델로 선정
- 기준모델 정확도: 0.760589

📌 평가지표

- 타겟이 불균형 클래스이기 때문에 정확도만 가지고 모델을 평가할 수 없으므로 f1 스코어를 함께 평가지표로 볼 것

3. 모델 학습

📌 capital_gain과 capital_loss를 더해 자본 총합계 'total_capital' 컬럼 생성

📌 불균형 클래스를 조정하기 위해 class weight, scale_pos_weight만 설정

📌 logistic regression, random forest, xgbclassifier catboostclassifier 모델 학습

📌 훈련/검증 정확도와 f1 score, auc score를 구함

3. 모델 학습

✔ logistic regression

```
훈련 정확도 0.7973219165603935
검증 정확도 0.7979595554745855
Report
              precision    recall  f1-score   support

           0       0.81      0.97      0.88      8358
           1       0.71      0.26      0.38      2620

    accuracy                           0.80     10978
   macro avg       0.76      0.61      0.63     10978
weighted avg       0.78      0.80      0.76     10978

f1 스코어 0.37905935050391937
auc점수 :  0.6127471691426964
```

✔ xgboost

```
훈련 정확도 0.874749498997996
검증 정확도 0.843960648569867
Report
              precision    recall  f1-score   support

           0       0.95      0.84      0.89      8358
           1       0.63      0.85      0.72      2620

    accuracy                           0.84     10978
   macro avg       0.79      0.85      0.81     10978
weighted avg       0.87      0.84      0.85     10978

f1 스코어 0.7226809130645944
auc점수 :  0.8466888239817771
```

✔ random forest

```
훈련 정확도 0.9999392724843627
검증 정확도 0.8606303516123155
Report
              precision    recall  f1-score   support

           0       0.89      0.94      0.91      8358
           1       0.76      0.61      0.68      2620

    accuracy                           0.86     10978
   macro avg       0.82      0.78      0.79     10978
weighted avg       0.85      0.86      0.86     10978

f1 스코어 0.6780303030303031
auc점수 :  0.7762750046123018
```

✔ catboost

```
훈련 정확도 0.8621789032610676
검증 정확도 0.8401348150847149
Report
              precision    recall  f1-score   support

           0       0.95      0.83      0.89      8358
           1       0.62      0.86      0.72      2620

    accuracy                           0.84     10978
   macro avg       0.78      0.85      0.80     10978
weighted avg       0.87      0.84      0.85     10978

f1 스코어 0.7203187250996015
auc점수 :  0.8478447307420416
```

3. 모델 학습

📌 과적합 가능성과 불균형 클래스를 잘 조정해 f1 score가 좋은 xgboost, catboost 모델만 RandomizedSearch CV로 하이퍼파라미터를 조정해 2차 모델 학습 실행

✔ xgboost

```
훈련 f1 score:  0.7381201590956668
검증 f1 score:  0.7134478424801006
Report
              precision    recall  f1-score   support

           0       0.95      0.83      0.88      6256
           1       0.61      0.86      0.71      1978

    accuracy                           0.83      8234
   macro avg       0.78      0.84      0.80      8234
weighted avg       0.87      0.83      0.84      8234

auc점수 :  0.8431292006185689
```

✔ catboost

```
훈련 f1 score:  0.7451420554191511
검증 f1 score:  0.7158250581026834
Report
              precision    recall  f1-score   support

           0       0.95      0.83      0.89      6256
           1       0.61      0.86      0.72      1978

    accuracy                           0.84      8234
   macro avg       0.78      0.84      0.80      8234
weighted avg       0.87      0.84      0.84      8234

auc점수 :  0.8434117200975435
```

⏩ 두 모델의 검증 f1 score와 auc score 모두 매우 근소한 차이를 가지는데, catboost 모델이 근소하게 평가지표들이 높은 수치를 보이고 있으므로 최종 모델로 catboost를 선택

3. 모델 학습

VAL ROC curve

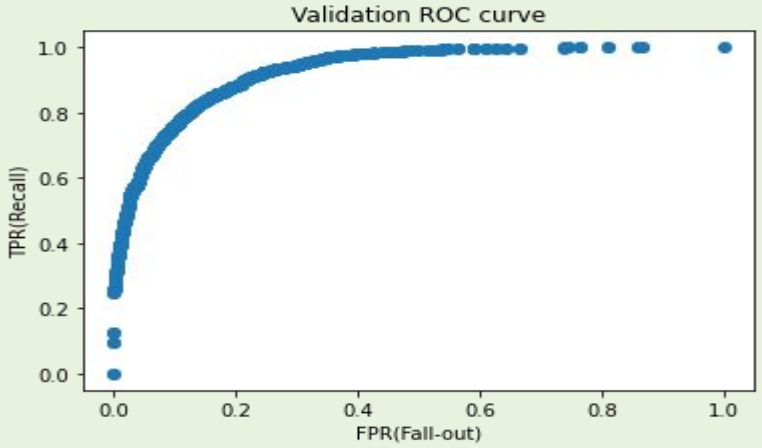

VAL AUC

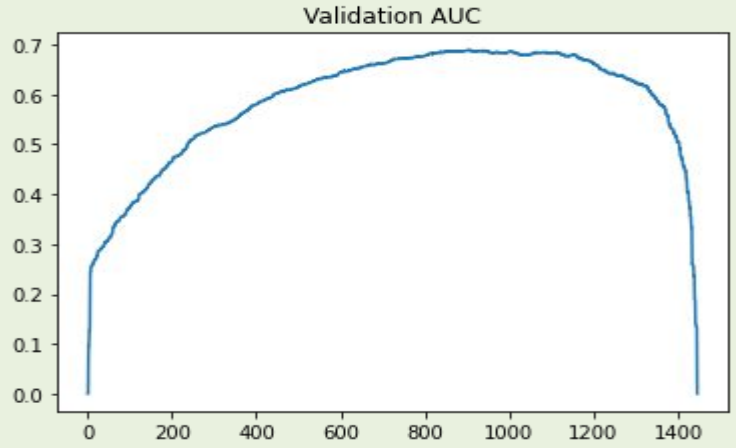

VAL 평가지표: 최적 임계값=0.5273530619303364일 때

```
Report
              precision    recall  f1-score   support

           0       0.95      0.84      0.89      6256
           1       0.63      0.85      0.72      1978

    accuracy                           0.84      8234
   macro avg       0.79      0.84      0.81      8234
weighted avg       0.87      0.84      0.85      8234

검정 정확도 0.8358027690065581
val_f1 스코어 0.7217915590008613
val_auc점수 :  0.8445362219710938
```

3. 모델 학습

TEST ROC curve

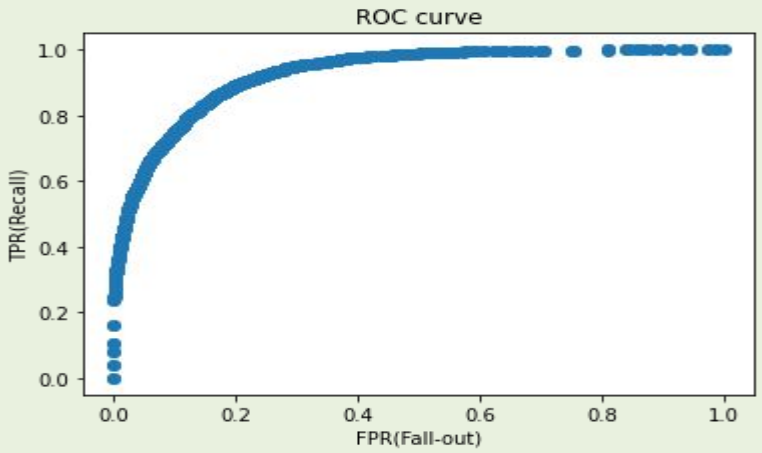

TEST AUC

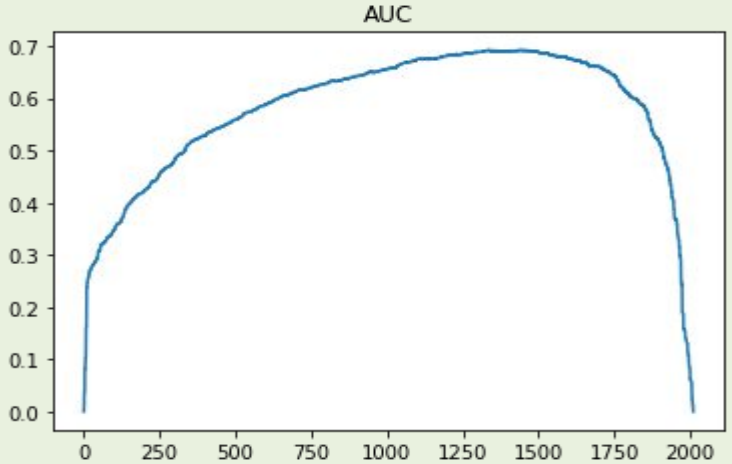

TEST 평가지표: 최적 임계값=0.45233375920960567일 때

```
Report
              precision    recall  f1-score   support

           0       0.96      0.81      0.87      8358
           1       0.59      0.89      0.71      2620

    accuracy                           0.82     10978
   macro avg       0.77      0.85      0.79     10978
weighted avg       0.87      0.82      0.83     10978

테스트 정확도 0.8360357077791948
test_f1 스코어 0.707242848447961
test_auc점수 :  0.846119729874381
```

3. 모델 학습

📌 모델 분석

- 테스트 정확도는 baseline 정확도보다 향상
- f1 score는 훈련/검증 데이터의 f1 score와 큰 차이를 보이지 않아 어느 정도 일반화 성능을 갖추었음을 확인
- 타겟 변수의 불균형 클래스 문제를 상당 부분 해결
- 과적합이 발생하지 않고 일반화가 원활히 이루어졌음

4. 해석 및 결론

📌 순열 중요도

Weight	Feature
0.0734 ± 0.0105	marital-status
0.0474 ± 0.0086	age
0.0449 ± 0.0115	educational-num
0.0405 ± 0.0030	total_capital
0.0190 ± 0.0024	capital-gain
0.0180 ± 0.0068	occupation
0.0154 ± 0.0021	hours-per-week
0.0098 ± 0.0011	capital-loss
0.0086 ± 0.0025	relationship
0.0045 ± 0.0033	workclass
0.0017 ± 0.0033	fnlwgt
0.0013 ± 0.0056	gender
-0.0003 ± 0.0008	native-country
-0.0010 ± 0.0016	race

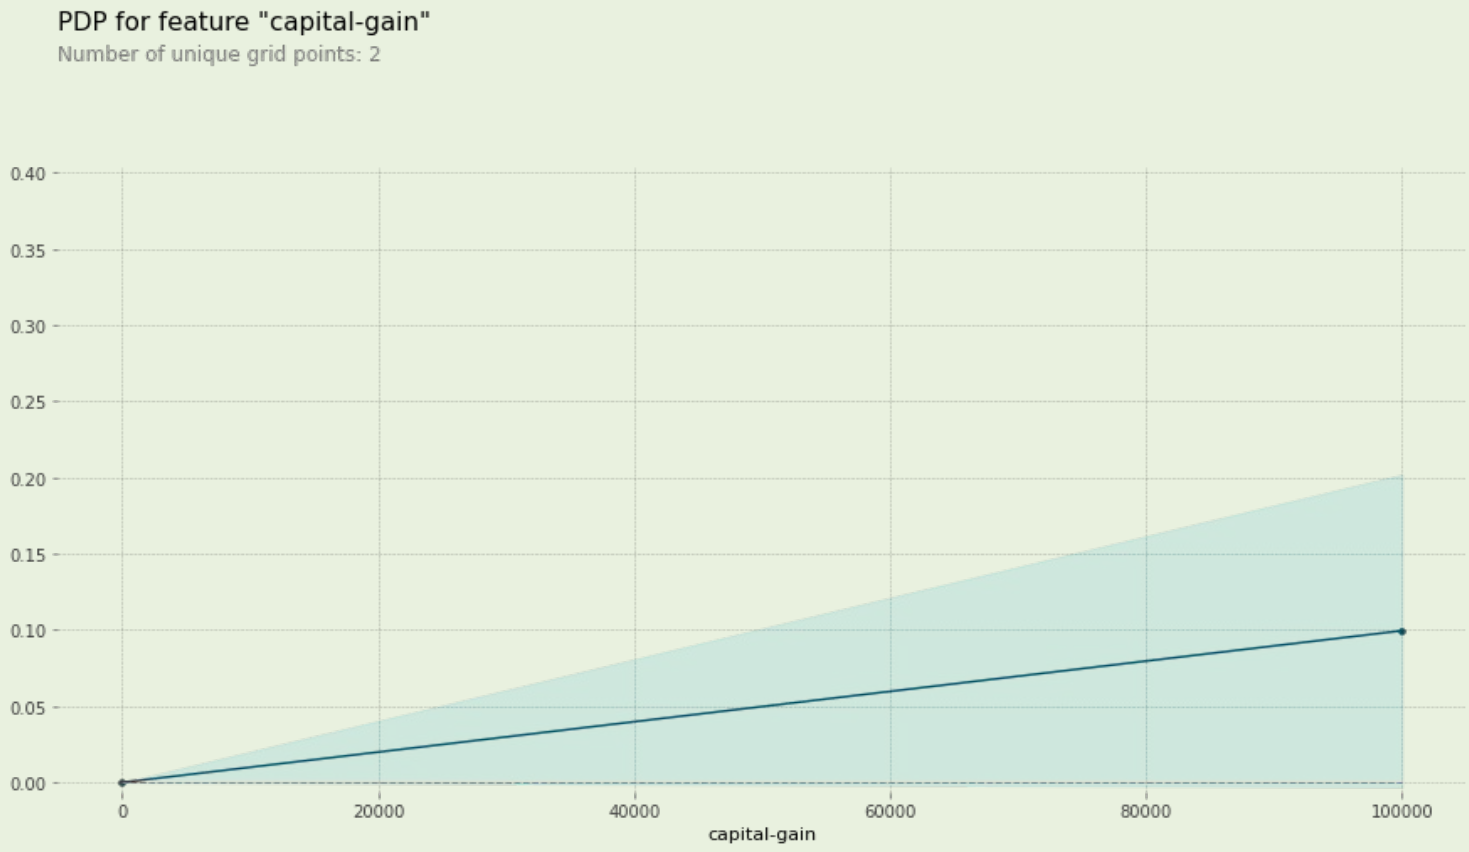

4. 해석 및 결론

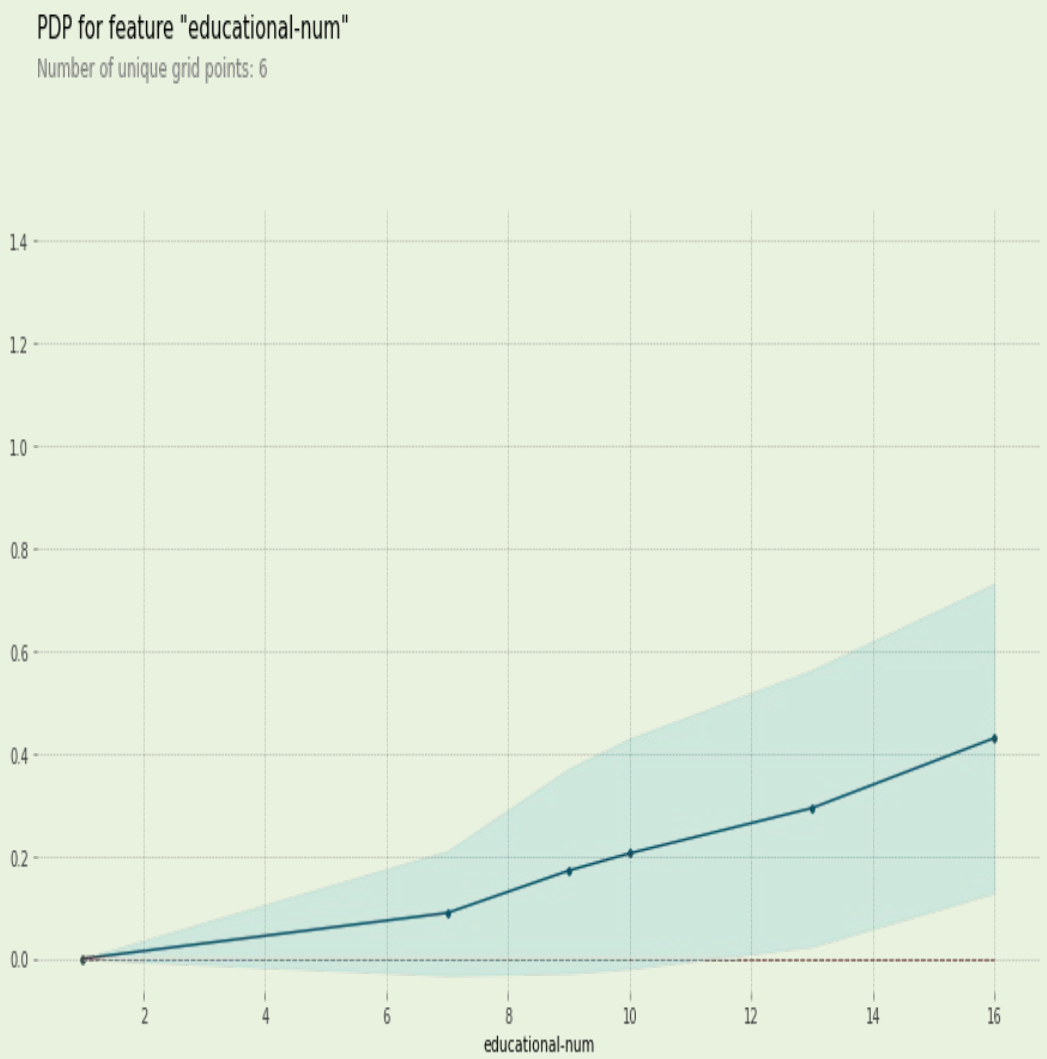
PDP for feature "educational-num"
Number of unique grid points: 6
1.4
1.2
1.0
0.8
0.6
0.4
0.2
0.0
2
4
6
8
10
12
14
16
educational-num

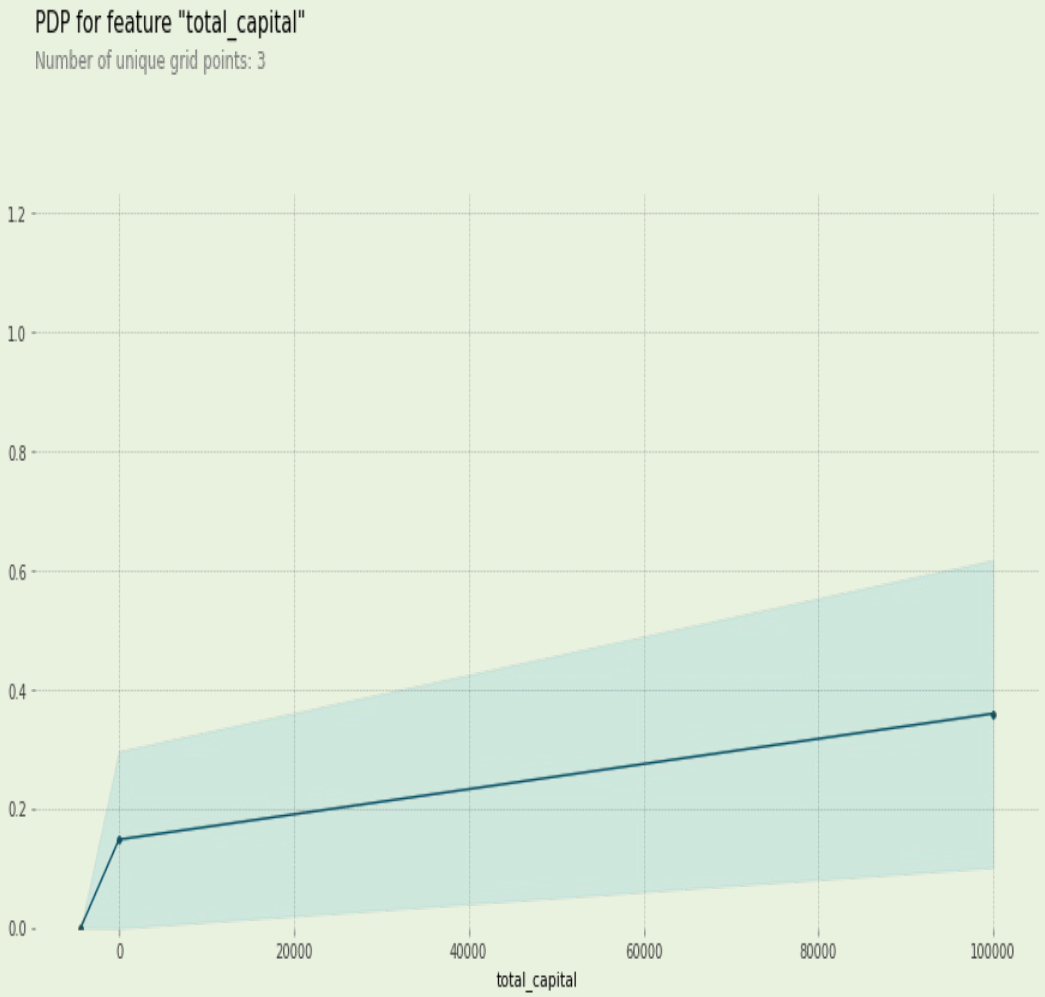
PDP for feature "total_capital"
Number of unique grid points: 3
1.2
1.0
0.8
0.6
0.4
0.2
0.0
0
20000
40000
60000
80000
100000
total_capital

4. 해석 및 결론

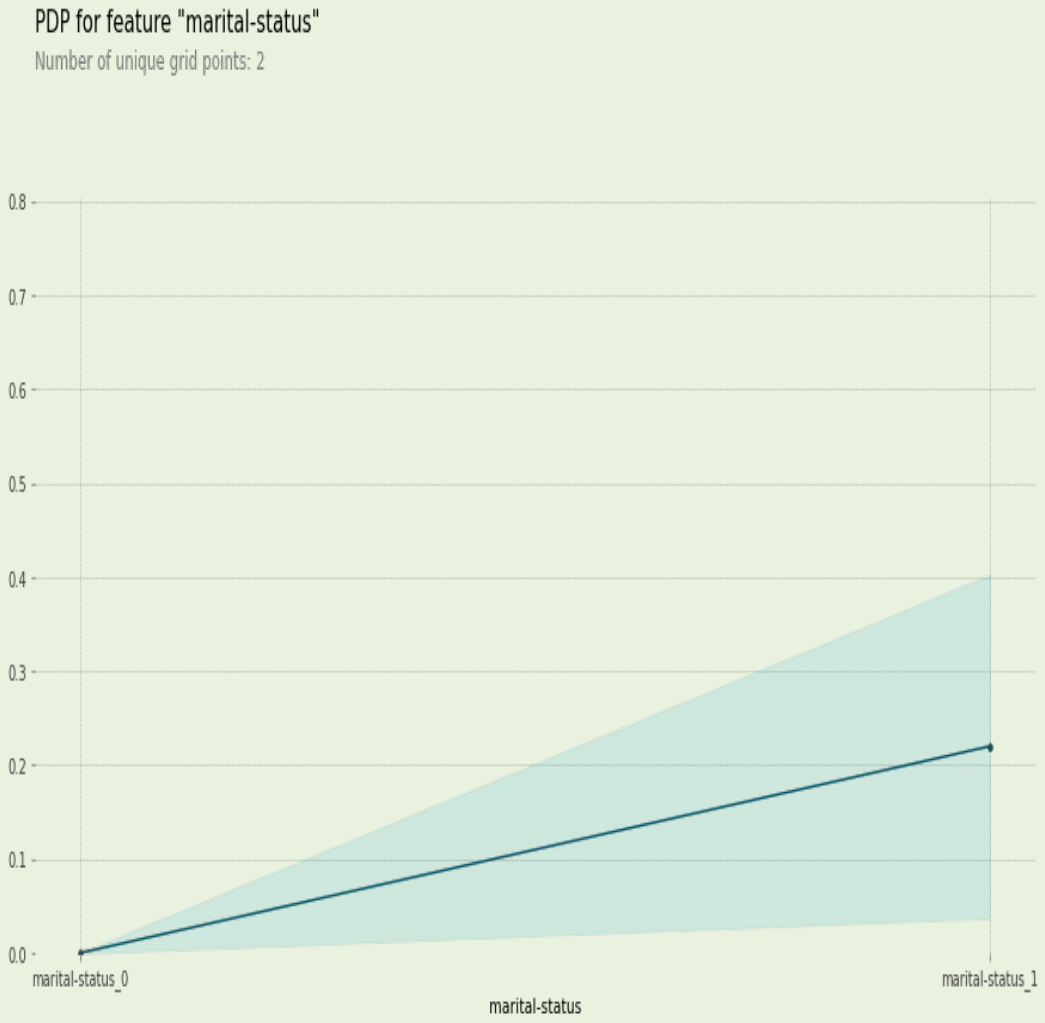
PDP for feature "marital-status"
Number of unique grid points: 2
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0.0
marital-status_0
marital-status_1
marital-status

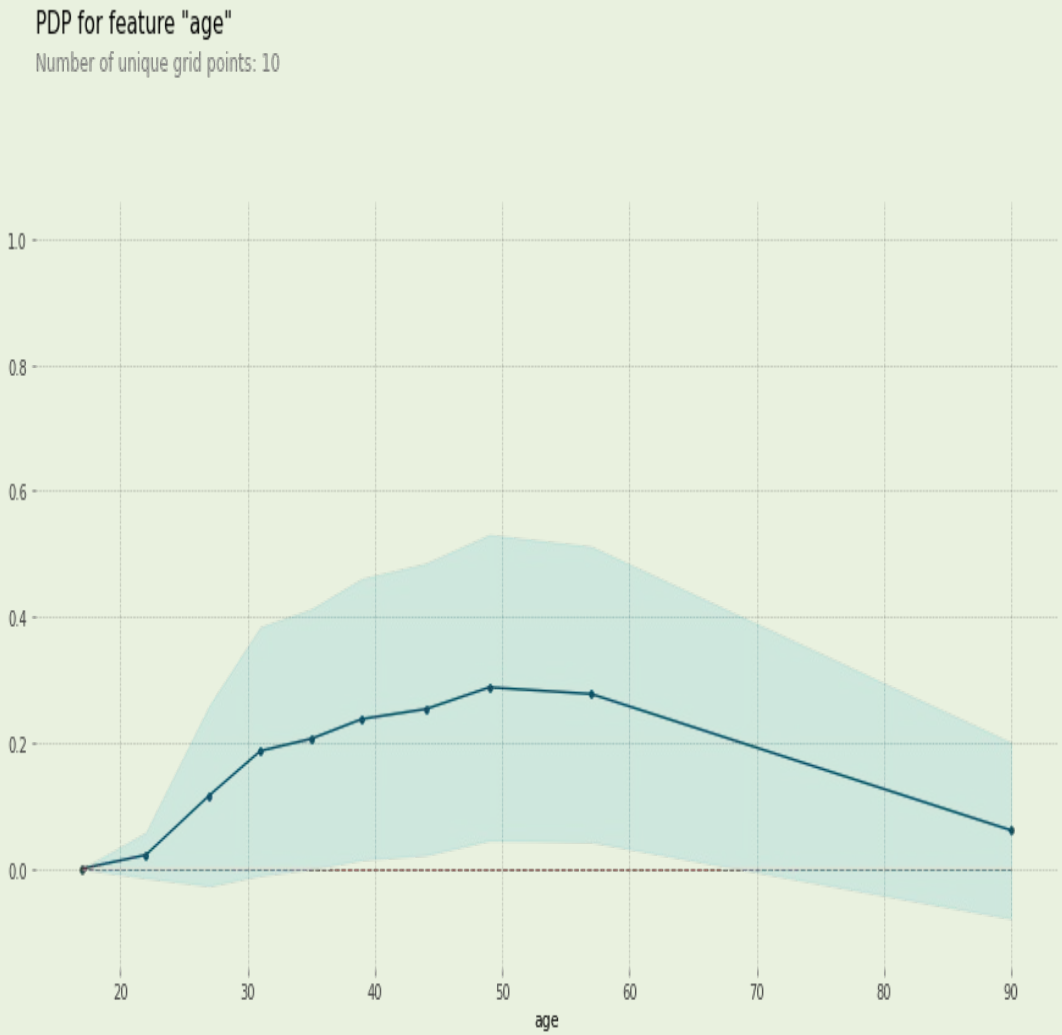
PDP for feature "age"
Number of unique grid points: 10
1.0
0.8
0.6
0.4
0.2
0.0
20
30
40
50
60
70
80
90
age

4. 해석 및 결론

📌 PDP plot

- capital gain, total capital이 많을수록 소득이 $50k보다 많을 확률이 커짐
- educational num이 높을수록 소득이 $50k보다 많을 확률이 커짐
- marital status=1일 때, 즉 결혼한 상태일 경우 소득이 $50k보다 많을 확률이 커짐
- age는 20~50대에서는 나이가 많을수록, 50대 이상에서는 나이가 적을수록 소득이 $50k보다 많을 확률이 커짐

📌 가설 2: 더 많은 교육을 받은 사람이 소득>$50000일 가능성이 높다.

- 가설 2의 교육 수준이 타겟 변수에 영향을 준다는 것이 확인됨

4. 해석 및 결론

📌 SHAP Summary plot

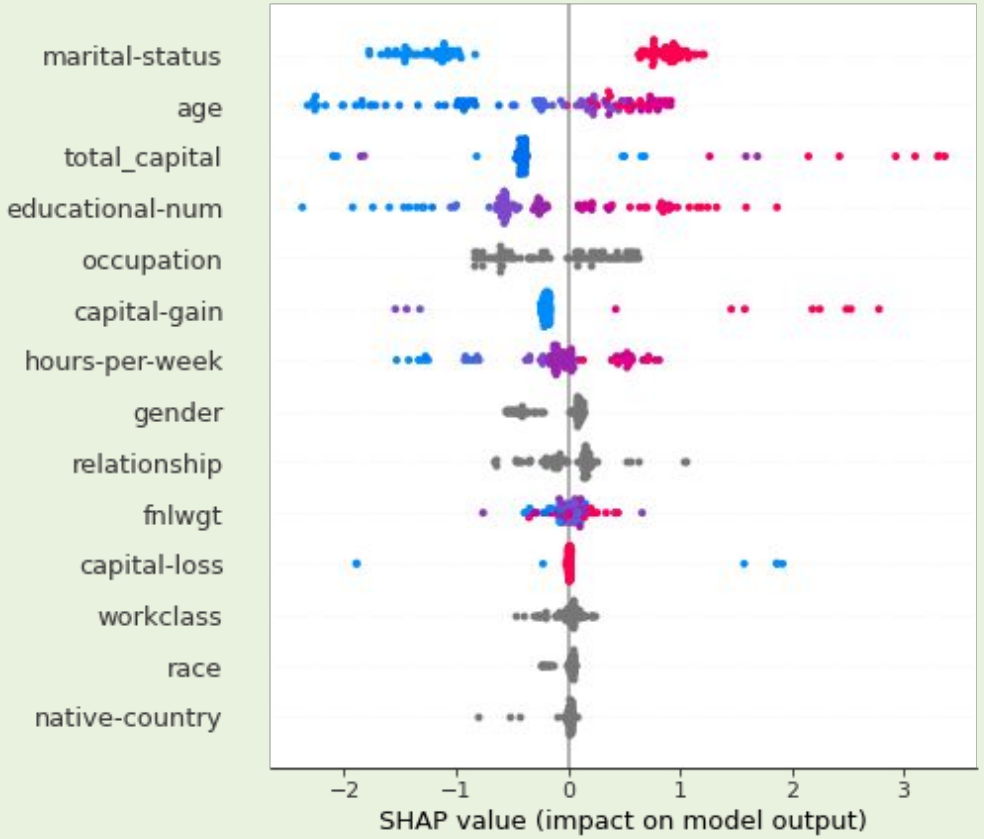

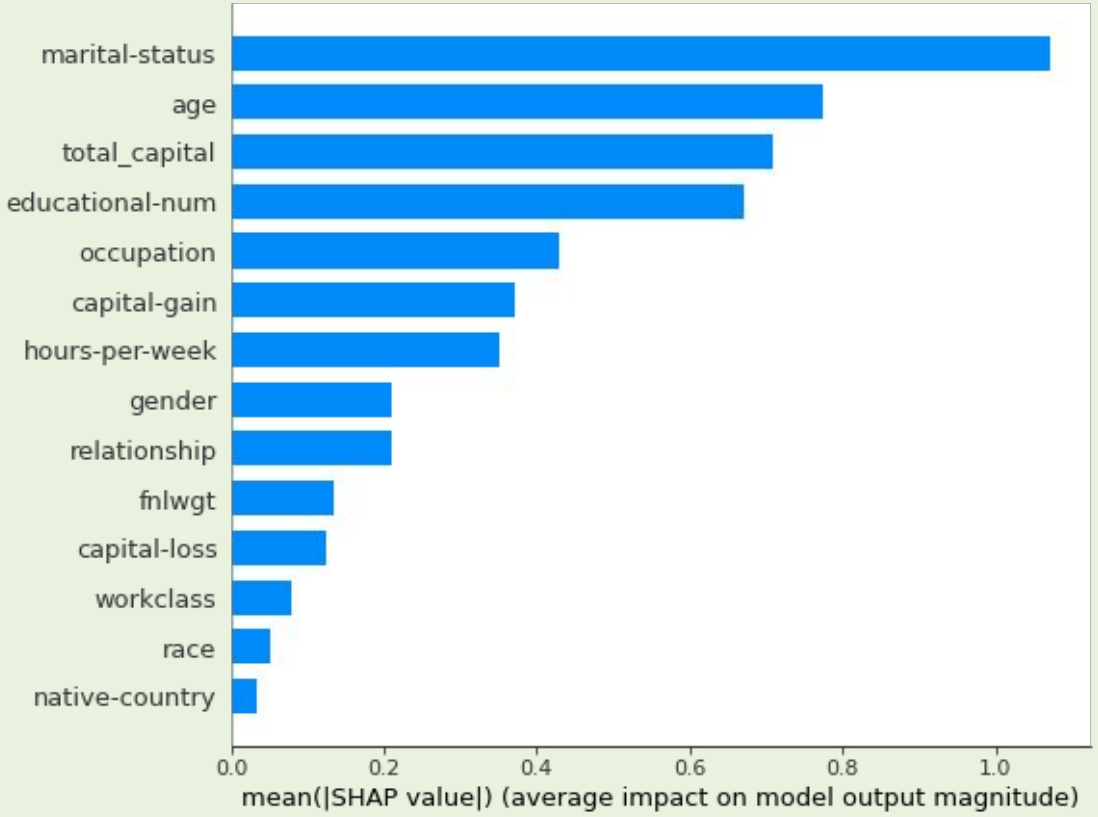

4. 해석 및 결론

📌 Shap summary plot

- positive/negative를 떠나 타겟 변수가 가장 크게 영향을 주는 feature는 marital status, age, total capital, educational-num 순
- 결혼 관계(marital status), 나이(age), 자본총합계(total capital), 자본이익(capital-gain)은 특성값이 작을수록 타겟에 negative한 영향을 주고, 특성값이 클수록 positive한 영향을 줌

📌 한계

- 카테고리를 디테일하게 전처리하지 못했다는 점

🔥 느낀 점

📌 아쉬운 점

- feature engineering을 더 다양하게 시도하고 싶었지만, 시간 분배에 실패해 하지 못한 점

- 카테고리형 변수를 인코딩하는 과정에서 다양한 인코딩 방법을 사용하지 못한 점

📌 그러나 catboost 모델의 어떤 장점이 있는지 알고 직접 적용했다는 점에서 의미있다고 생각

감사합니다

THANK YOU!